

简答题题库与标准答案（含 SVM 专题）

覆盖：往年卷全部简答 + jk2 新增考点 + SVM 专项。
用法：先盖住答案自答，再对照。★标注为高频/官方重点。

第1章 绪论

1. 人工智能、机器学习、神经网络的区别与联系 ★★★

- 人工智能(AI)：最宏观的概念，研究如何让机器具有智能、模拟人类智能行为的学科。
- 机器学习(ML)：AI 的一个子领域，研究让计算机从数据中自动学习规律、实现自我完善的方法。
- 神经网络(NN)：机器学习中的一类具体模型/方法，模仿生物神经系统结构。
- 关系：三者是逐层包含关系 $AI \supset ML \supset NN$ 。深度学习是使用深度神经网络的机器学习。

2. 符号主义与连接主义的主要区别 ★★★

- 符号主义：认为智能来源于对符号的逻辑运算，基于知识和规则进行推理（如专家系统、逻辑推理）。核心是"物理符号系统假设"。可解释性强。
- 连接主义：认为智能来源于大量神经元的连接与并行计算，通过数据训练调整连接权重（如神经网络）。擅长感知类任务，黑盒性强。
- （今年补充行为主义：认为智能源于智能体与环境的交互和反馈，强调感知-动作，如强化学习、机器人控制。）

3. 物理符号系统 vs 人工神经网络系统的差别

- 物理符号系统：以离散符号为基本单元，串行逻辑运算，知识显式表示，可解释。
- 人工神经网络：以神经元为单元，连续数值、并行分布式计算，知识隐式存于权重，不易解释。

4. 归纳推理 vs 演绎推理（jk2 新增）

- 演绎推理：从一般到特殊，前提为真则结论必然为真（如三段论、归结推理）。
- 归纳推理：从特殊到一般，由个别事例归纳出普遍规律，结论具有或然性（机器学习本质是归纳）。

对比项	归纳推理(Induction)	演绎推理(Deduction)
方向	从特殊到一般	从一般到特殊
过程	从实例/数据中提炼规律和规则	从已知公理/规则推导具体结论
结论确定性	不一定正确（概率性/或然性）	前提真则结论必真（确定性）
典型场景	机器学习（从数据学模型）	逻辑推理（三段论）
AI 代表	FOIL 算法：从正例/反例归纳规则	归结法(Resolution)：从公理推导矛盾

- 课件例子：归纳=FOIL 算法从训练样例中不断测试、学习推理规则；演绎=知识图谱推理中学得规则后，给变量赋具体值，经演绎得到新知识。

第2章 知识工程

5. 知识表示方法有哪些？各自的表示形式 ★★★

- 谓词逻辑表示法：用一阶谓词公式表示，如 $\forall x(Man(x) \rightarrow Mortal(x))$ 。
- 产生式表示法：用 IF-THEN 规则表示，如 IF 发烧 AND 咳嗽 THEN 感冒。
- 框架表示法：用槽(slot)和值组成的结构化框架表示，如"汽车"框架含颜色、品牌槽。
- 语义网络：用节点表示概念、有向弧表示关系（ISA、AKO 链）。
- 知识图谱：以结构化形式描述实体、概念及其关系的大规模语义网络。

6. 逻辑表示法的优缺点

- 优点：严密精确、自然（接近自然语言）、易于逻辑演绎推理、便于机器实现。
- 缺点：表达效率低、不便表示不确定性/模糊知识、易产生组合爆炸、难以表示过程性和启发性知识。

7. 产生式系统中推理机的推理方式 ★★

- 正向推理（数据驱动）：从已知事实出发，匹配规则前件，推出结论，直到达到目标。
- 反向推理（目标驱动）：从目标假设出发，反向寻找支持它的证据/规则。
- 双向推理：正反向结合，从两端向中间推进，提高效率。

8. 推理的三个层次（jk2 新增）

- 关联推理（相关关系）→ 干预推理（做某动作的效果）→ 反事实推理（如果当初...会怎样）。这是因果推理的三个层次（Pearl 因果阶梯）。

第3章 确定性推理

9. 简述反演法（归结反演）求取某个问题答案的过程☆☆☆

- 1. 把已知前提用谓词公式表示，并化为子句集 S。
 - 2. 把待求解的问题的否定用谓词公式表示，用一个求解谓词 ANSWER 附加到其上，化为子句加入 S（构造带 ANSWER 的重言式）。
 - 3. 对新子句集反复应用归结原理进行归结。
 - 4. 当归结出的子句只含 ANSWER 谓词时，ANSWER 中的项就是问题的答案。
- （若只是证明命题：将结论取反加入子句集，归结出空子句 □ 即证明结论成立。）

第4章 不确定性推理

10. 不确定性推理的"不确定性"主要表现在哪些方面☆☆

- 证据的不确定性：观测数据可能有误差、不完整（如传感器噪声）。
- 知识（规则）的不确定性：规则本身是经验性的、非绝对（如"发烧多半是感冒"）。
- 推理过程/结论的不确定性：不确定性沿推理链传播、组合，导致结论不确定。

11. 什么是不确定性推理？需解决的基本问题☆☆

- 定义：在证据和知识都不完全确定的情况下，运用不确定性知识进行的推理。
- 基本问题：①不确定性的表示（证据与规则如何度量）；②不确定性的传递/传播（前提→结论如何算）；③不确定性的合成（多条规则支持同一结论如何合并）；④结论的不确定性更新与决策。

12. 什么是贝叶斯定理？解决什么问题？刻画因果还是相关？☆☆☆

- 公式： $P(H|E) = P(E|H) \cdot P(H) / P(E)$ 。
- 解决问题：由易统计的先验概率 $P(H)$ 和似然 $P(E|H)$ ，求难以直接统计的后验概率 $P(H|E)$ （逆概率问题）。例如由 $P(\text{咳嗽}|\text{支气管炎})$ 求 $P(\text{支气管炎}|\text{咳嗽})$ 。
- 刻画的是相关关系，不是因果关系（贝叶斯定理只反映变量间的概率相关，不能确定因果方向）。

第5章 搜索与优化

13. 回溯搜索策略和图搜索策略的区别☆☆

- 回溯搜索：深度优先思想，沿一条路径试探，失败则回退换路；一般不记录已访问全部节点，可能重复搜索、可能陷入死循环。
- 图搜索：用 OPEN 表和 CLOSED 表记录待扩展和已扩展节点，避免重复访问同一状态，能处理有环图，保证系统性和完备性。

14. AI 中的搜索 vs 数据库检索的差异

- 搜索：解不是预先存好的，需在状态空间中通过扩展节点动态"生成/构造"路径，关注路径与代价。
- 数据库检索：数据已存储，按索引精确匹配查询，直接取出，不涉及状态转移和路径代价。

15. 启发函数的可容性与一致性（jk2 新增）☆☆

- 可容性(admissible)：对任意节点 n ， $h(n) \leq h^*(n)$ (h 为到目标的真实最小代价)，即启发函数从不高估。可容 $\Rightarrow A^*$ 找到最优解。
- 一致性/单调性(consistent)：对任意相邻节点 $n、n'$ ， $h(n) \leq c(n,a,n') + h(n')$ ，且 $h(\text{目标})=0$ （三角不等式）。一致 $\Rightarrow$ 一定可容，且保证 $f(n)$ 非递减，故每个节点首次扩展即最优（无需重开节点）。

性质	定义	作用
可容性	$h(n) \leq h^*(n)$ ，永不高估真实代价	保证 A^* 最优性
一致性	$h(n) \leq c(n,a,n') + h(n')$ ，且 $h(\text{goal})=0$	保证 $f(n)$ 非递减，比可容性更严格

- 关系：一致性 $\Rightarrow$ 可容性（反之不成立）。
- 直觉：可容="乐观估计"（8 数码用"不在位将牌数"做 $h(n)$ ，永远 $\leq$ 真实步数）；一致="三角不等式"（从 n 直接到目标 $\leq$ 先到邻居 n' 再到目标）。
- 华工《A 星算法》数学证明：
 - 定理 1.3： $h(n)$ 可容 $\Rightarrow A^*$ 找到最优解。
 - 定理 1.4： $h_2 \geq h_1$ (h_2 支配 h_1) $\Rightarrow A_2$ 展开节点 $\subseteq A_1$ 展开节点（更好的启发式=更高效率）。
 - 推论 1.1： 所有 $f(n) < f^*(s)$ 的节点最终都会被展开。

16. 评价函数与启发函数（补充）

- 评价函数 $f(n)$ ：搜索算法给每个候选节点打分的函数，每次扩展选 $f(n)$ 值最优的节点。
- 直观： $g(n)$ 是"已付成本"， $h(n)$ 是"预估还需成本"， $f(n)$ 就是经过 n 的路径的总估计代价。

算法	f(n)	含义
贪心搜索	f(n) = h(n)	只看离目标"有多远"（不保证最优）
UCS(一致代价)	f(n) = g(n)	只看从起点"花了多少"（后视）
A*	f(n) = g(n) + h(n)	两者结合，最优+高效

- A* 每次选 OPEN 表中 f 最小的节点扩展——看起来最有希望的路先走。
- AlphaGo 原理：蒙特卡洛树搜索(MCTS) + 深度神经网络（策略网络选走法、价值网络评估局面），结合强化学习自我对弈训练。

第6章 机器学习

17. 机器学习中的"泛化"能力是指什么☆☆

指模型对训练时未见过的新数据做出正确预测的能力。泛化好说明模型学到的是数据背后的普遍规律，而非死记训练样本（避免过拟合）。

18. 分类、聚类、回归的区别☆☆☆

类型	输出	是否有标签(监督)	目标
分类	离散类别	有监督	学习决策边界，预测类别
回归	连续数值	有监督	拟合输入到连续输出的映射
聚类	无预定义标签的分组	无监督	发现数据内在结构，物以类聚

19. 聚类 vs 分类差异 + K-means 步骤☆☆☆

- 差异：分类有标签（监督），聚类无标签（无监督）。
- K-means 步骤：①随机选 K 个初始质心；②将每个样本分配到最近的质心所在簇；③重新计算各簇均值作为新质心；④重复②③直到质心不再变化（收敛）。
- K-means 特点：需预先指定 K；对初始值敏感；只能发现凸形（球形）簇；对噪声/离群点敏感。

20. 简述梯度下降算法的步骤☆☆☆

①初始化参数 θ ；②计算损失函数对参数的梯度 $\nabla J(\theta)$ ；③沿负梯度方向更新 $\theta \leftarrow \theta - \alpha \cdot \nabla J(\theta)$ （ α 为学习率）；④重复②③直到收敛（梯度趋近 0 或损失不再下降）。

21. DBSCAN 密度聚类的基本思想、过程与缺点☆☆☆

- 思想：基于密度，把足够高密度的区域划为簇。用两个参数：邻域半径 ϵ 、最小点数 MinPts。核心点（ ϵ 邻域内点数 $\geq$ MinPts）不断扩展相连的点形成簇。
- 过程：①任取未访问点，若其为核心点，建立新簇并把其密度可达的所有点纳入；②非核心点标记为边界点或噪声；③重复直到所有点被访问。
- 缺点：①对参数 ϵ 、MinPts 敏感；②密度不均匀时效果差；③高维数据下距离度量失效（维数灾难）。
- 优点：无需指定簇数 K，能发现任意形状簇，能识别噪声。

22. 什么是交叉验证法？有什么用处☆☆☆

- k 折交叉验证：将数据集分成 k 份，每次用 k-1 份训练、1 份验证，轮流 k 次，取平均性能。
- 用处：更充分利用有限数据，更可靠地评估模型泛化能力，减小因单次划分带来的偶然性，辅助模型选择与调参、防止过拟合。

23. 机器学习系统构成 + 结果可预测吗 + AI 风险☆☆☆

- 系统构成：数据采集与预处理 → 特征工程 → 模型（假设空间）→ 训练算法（优化目标）→ 评估/验证 → 部署预测，评估结果反馈调整。
- 是否可预测：基于数据驱动的机器学习是从数据中归纳规律而非死记数据；但结果不完全可预测——依赖数据质量、存在统计误差、黑盒模型决策不透明。
- 风险：数据偏见导致歧视性决策；黑盒不可解释导致责任难追溯；被恶意样本攻击；隐私泄露等。

24. 生成式方法 VS 判别式方法（jk2 新增）☆☆☆

- 生成式模型：学习联合概率分布 $P(x,y)$ ，再由贝叶斯求 $P(y|x)$ 。可生成新样本。代表：朴素贝叶斯、贝叶斯网络、HMM。
- 判别式模型：直接学习条件概率 $P(y|x)$ 或决策边界。通常分类精度更高。代表：逻辑回归、SVM、决策树、神经网络。
- 区别：生成式建模数据如何产生（关注分布），判别式直接建模分类边界（关注区分）。

25. 监督学习 vs 强化学习（jk2 新增）

- 监督学习：从带标签的样本 (x, y) 中学习映射，有明确"正确答案"作监督信号。
- 强化学习：智能体通过与环境交互获得奖励信号（无逐样本标签），目标是学习使累积奖励最大的策略，反馈有延迟。

26. 深度学习 vs 传统机器学习（jk2 新增）

- 传统 ML：依赖人工设计特征，模型较浅，小数据可用。
- 深度学习：用深层神经网络自动学习特征（端到端），需大数据和算力，在图像/语音/NLP 上表现更优，但可解释性差。

27. 分类模型评价指标与优化（jk2 新增）☆☆☆

设混淆矩阵：TP 真阳、FP 假阳、TN 真阴、FN 假阴。

- 精度 $\text{Precision} = \text{TP}/(\text{TP}+\text{FP})$ ：预测为正中真正为正的比例。
- 召回率 $\text{Recall} = \text{TP}/(\text{TP}+\text{FN})$ ：真实为正中被正确找出的比例。
- 准确率 $\text{Accuracy} = (\text{TP}+\text{TN})/\text{总数}$ 。
- $\text{F1} = 2 \cdot \text{P} \cdot \text{R}/(\text{P}+\text{R})$ ：精度与召回的调和平均。
- 精度与召回常此消彼长，用 F1 或 PR/ROC 曲线综合权衡。

【新增】强化学习 (jk1+jk2 双命中，务必掌握)

28. 马尔科夫决策过程(MDP)有哪些元素☆☆

五元组 (S, A, P, R, γ):

- **S**: 状态集合; **A**: 动作集合;
- **P**: 状态转移概率 $P(s'|s,a)$; **R**: 奖励函数 $R(s,a)$;
- **γ** : 折扣因子 ($0 \leq \gamma \leq 1$), 权衡当前与未来奖励。
- 满足马尔科夫性: 下一状态只依赖当前状态和动作, 与历史无关。

29. 强化学习的目标与基本过程☆☆

- 目标: 学习一个最优策略 π^* , 使智能体从环境获得的累积 (折扣) 奖励期望最大。
 - 目标函数: $\pi^* = \arg\max_{\pi} E[\sum_{t=0}^{\infty} \gamma^t \cdot r_t]$ 。
- 基本过程: 智能体在状态 s 下选动作 $a \rightarrow$ 环境给出奖励 r 和新状态 $s' \rightarrow$ 智能体据此更新策略 $\rightarrow$ 循环。核心是"状态-动作-奖励"的试错交互。
- 关键要素:
 - 试错学习: 智能体通过尝试不同动作、观察奖励来学习。
 - 延时奖励: 当前动作可能影响未来所有奖励 (不同于监督学习的即时反馈)。
 - 探索 vs 利用(exploration vs exploitation): 利用是选当前已知最优动作, 探索是尝试新动作以发现更优策略; 用 ϵ -贪心策略 / Softmax 策略平衡两者。
- 贝尔曼方程 (强化学习的数学基础): 描述状态价值/动作价值的递归关系, 最优策略使价值函数最大化:
 - $V^*(s) = \max_a \sum P(s'|s,a)[R(s,a) + \gamma \cdot V^*(s')]$ 。

第7章 神经网络与深度学习

30. BP 算法适用什么结构? 描述学习过程☆☆☆

- 适用结构: (多层) 前馈神经网络 (全连接前馈网络)。
- 学习过程: ①前向传播: 输入经各层加权求和+激活, 逐层计算到输出; ②计算输出与目标的误差 (损失); ③误差反向传播: 将误差从输出层向输入层逐层反传, 用链式法则求损失对各权重的梯度; ④用梯度下降更新相邻层神经元之间的连接权重 (和偏置); ⑤重复直到收敛。

31. 深度学习模型举例 + 应用

- CNN 卷积神经网络 $\rightarrow$ 图像分类、目标检测。
- RNN/LSTM 循环神经网络 $\rightarrow$ 语音识别、机器翻译、时序预测。
- Transformer $\rightarrow$ 大语言模型、机器翻译。
(GAN $\rightarrow$ 图像生成; 也可答)

SVM 支持向量机专题 (确定考简答)☆☆☆

S1. 支持向量机的优点在哪? 用示意图解释结构风险最小化的含义与合理性 ★核心题★


SVM 的优点:

1. 基于结构风险最小化原则, 泛化能力强, 适合小样本。
2. 最终决策只由少数支持向量决定, 模型稀疏、计算高效。
3. 通过核函数巧妙解决非线性分类, 避免高维显式变换 (避开维数灾难)。
4. 是凸二次规划问题, 存在唯一全局最优解, 不会陷入局部极小。

结构风险最小化(SRM)的含义 (配示意图):

- 真实 (期望) 风险 $R(a) \leq$ 经验风险 $R_{\text{emp}}(a)$ + 置信范围 (与 VC 维/模型复杂度有关)。
- 经验风险: 模型在训练集上的误差; 置信范围: 模型复杂度 (VC 维) 带来的泛化误差上界。
- 传统方法只最小化经验风险(ERM), 样本有限时不合理 (易过拟合)。
- SRM = 在保证经验风险较小的同时, 控制模型复杂度 (VC 维), 使两者之和 (真实风险上界) 最小。

示意图 (记住这条 U 形曲线):



- **合理性**: 模型太简单→经验风险大 (欠拟合); 太复杂→置信范围大 (过拟合)。只有折中使总和最小, 才能得到泛化能力最好的模型。SVM 通过最大化分类间隔 ($\text{Margin} = 2/\|w\|$) 来控制 VC 维, 正是实现 SRM 的具体手段。

S2. SVM 相关概念速记

- **最优分类超平面**: 能无错误划分两类、且使两类中最近样本到超平面距离(分类间隔 **Margin**)最大的超平面。($w \cdot x - b = 0$)。
- **分类间隔 $\text{Margin} = 2/\|w\|$** , 最大化间隔 $\Leftrightarrow$ 最小化 $\frac{1}{2}\|w\|^2$ (二次规划)。
- **支持向量**: 距离超平面最近、决定超平面位置的那些样本 (对应拉格朗日乘子 $a_i \neq 0$ 的样本)。
- **松弛变量 ξ 与惩罚因子 C** : 处理线性不可分, C 在最大间隔与误分之间折衷。
- **核函数**: $K(x_i, x_j) = \Phi(x_i) \cdot \Phi(x_j)$, 把样本空间内积替换为核函数, 隐式实现高维映射, 避免显式非线性变换。常用: 多项式核、径向基核(RBF)、Sigmoid 核。满足 Mercer 条件的函数即为核函数。