

计算题题型与解法模板（40 分核心）

计算题形式与 往年卷/人工智能复习题-2023.docx 完全一致。  
本文给出 6 大题型的解题模板 + 例题完整过程，考前把每个模板"手推一遍"。  
已知情报：神经网络大题必考复杂版（AND 神经元 / 加法节点梯度的扩展）。

题型一 · 进阶:含 ∃(Skolem 化)+ 函数项的双变量归结题

题目

用归结法证明结论 G。

前提:

F1:  $\forall x ( P(x) \rightarrow \exists y Q(x, y) )$   
每个 P 都对应某个与之有 Q 关系的 y

F2:  $\forall x \forall y ( Q(x, y) \rightarrow R(y) )$   
Q 关系的第二个参数必有性质 R

F3:  $P(a)$  (a 为常量)

结论:

G:  $\exists z R(z)$

第1步 前提子句化(重点在 F1 的 Skolem 化)

F1:  $\forall x ( P(x) \rightarrow \exists y Q(x,y) )$

消蕴含:

$\forall x ( \neg P(x) \vee \exists y Q(x,y) )$

Skolem 化消去  $\exists y$ 。因为 y 在  $\forall x$  的辖域内,y 依赖于 x,所以用 Skolem 函数 f(x) 而不是常量:

$\forall x ( \neg P(x) \vee Q(x, f(x)) )$

去全称量词:

C1:  $\neg P(x) \vee Q(x, f(x))$

关键: $\exists$  在  $\vee$  内部,必须用 **Skolem 函数** f(x) 代入,不能用常量。这就是函数项的来源。

F2: 消蕴含,变量改名

C2:  $\neg Q(u, v) \vee R(v)$

F3:

C3:  $P(a)$

第2步 结论取否定并子句化

$\neg G: \neg \exists z R(z) \equiv \forall z \neg R(z)$

C4:  $\neg R(z)$  (z 为全称变量)

第3步 归结(每步做合一)

归结① C3 与 C1 — 互补文字 P

C3:  $P(a)$

C1:  $\neg P(x) \vee Q(x, f(x))$

合一: {x/a}

消去 P, 得:

R1:  $Q(a, f(a))$  ← 注意函数项 f(a) 被生成

归结② R1 与 C2 — 互补文字 Q

R1:  $Q(a, f(a))$   
C2:  $\neg Q(u, v) \vee R(v)$

合一:  $\{u/a, v/f(a)\}$        $\leftarrow$  变量  $v$  绑定到函数项  $f(a)$   
消去 Q, 得:  
R2:  $R(f(a))$

归结③ R2 与 C4 — 互补文字 R

R2:  $R(f(a))$   
C4:  $\neg R(z)$

合一:  $\{z/f(a)\}$        $\leftarrow$  全称变量  $z$  绑定到  $f(a)$   
消去 R, 得:  
R3:  $\Box$  (空子句)

第4步 结论

归结出空子句  $\Box$ ,故原结论

G:  $\exists z R(z)$       得证。

本题涉及的三个高频考点

1. Skolem 化规则(最易失分)
- $\exists$  前面没有  $\forall$  管辖  $\rightarrow$  用 Skolem 常量(如 c)。
  - $\exists$  前面有  $\forall x$  管辖  $\rightarrow$  用 Skolem 函数  $f(x)$ ,把所依赖的全称变量作参数。
  - 本题 F1 的  $y$  依赖  $x$ ,所以必须写  $f(x)$ ,这是全题的关键。
2. 变量与函数项的合一
- 变量可以绑定到函数项: $\{v/f(a)\}$  合法。
  - 但要过 **occur check**:若试图让  $v$  与含  $v$  的项(如  $f(v)$ )合一则失败。本题没触发。
3. 合一代换要贯穿始终
- $\{x/a\}$  一旦确定, $Q(x,f(x))$  立即变成  $Q(a,f(a))$ ,函数项内部的  $x$  也要同步替换,漏替换是常见错误。

题型二：贝叶斯网络推理（第4章）☆☆☆☆

通用方法

- 联合概率分解： $P(\text{所有变量}) = \prod P(\text{变量}|\text{其父节点})$ 。
- 求  $P(A|B) = P(A,B)/P(B)$ ，分子分母都用**全概率公式**对其余变量求和（边缘化）。

例题（往年卷计算题2）：求  $P(\neg C|\neg E)$

贝叶斯网：S、C 是 E 的父节点。CPT：  
 $P(S)=0.4, P(C)=0.3; P(E|S,C)=0.9, P(E|S,\neg C)=0.3, P(E|\neg S,C)=0.5, P(E|\neg S,\neg C)=0.1$ 。

注意  $P(\neg E|\cdot) = 1 - P(E|\cdot)$ ：  $P(\neg E|S,C)=0.1, P(\neg E|S,\neg C)=0.7, P(\neg E|\neg S,C)=0.5, P(\neg E|\neg S,\neg C)=0.9$ 。

第一步 求  $P(\neg E)$ （对 S、C 四种组合求和，S、C 独立）：

$$\begin{aligned} P(\neg E) &= P(\neg E|S,C)P(S)P(C) + P(\neg E|S,\neg C)P(S)P(\neg C) \\ &\quad + P(\neg E|\neg S,C)P(\neg S)P(C) + P(\neg E|\neg S,\neg C)P(\neg S)P(\neg C) \\ &= 0.1\cdot 0.4\cdot 0.3 + 0.7\cdot 0.4\cdot 0.7 + 0.5\cdot 0.6\cdot 0.3 + 0.9\cdot 0.6\cdot 0.7 \\ &= 0.012 + 0.196 + 0.090 + 0.378 = 0.676 \end{aligned}$$

第二步 求  $P(\neg C,\neg E)$ （固定  $\neg C$ ，对 S 求和）：

$$\begin{aligned} P(\neg C,\neg E) &= P(\neg E|S,\neg C)P(S)P(\neg C) + P(\neg E|\neg S,\neg C)P(\neg S)P(\neg C) \\ &= 0.7\cdot 0.4\cdot 0.7 + 0.9\cdot 0.6\cdot 0.7 \\ &= 0.196 + 0.378 = 0.574 \end{aligned}$$

第三步：  $P(\neg C|\neg E) = P(\neg C,\neg E)/P(\neg E) = 0.574/0.676 \approx \mathbf{0.849}$ 。

⚠ 注意：往年卷 AI导论.md 里那份答案把  $P(\neg E)$  算成 0.58 是**错的**（它漏乘/算错了第一项系数）。正确  $P(\neg E)=0.676, P(\neg C|\neg E)\approx 0.849$ 。计算时务必逐项核对  $P(S)、P(C)$  与  $\neg$  的搭配。

例题（贝叶斯最优分类器）：

先验  $P(h1)=0.3,P(h2)=0.3,P(h3)=0.4$ ；似然  $P(d|h1)=0.5,P(d|h2)=0.3,P(d|h3)=0.2$ 。h1 判正，h2、h3 判负。

- 后验(未归一)：  $P(h1|d)\propto 0.3\cdot 0.5=0.15$ ；  $P(h2|d)\propto 0.3\cdot 0.3=0.09$ ；  $P(h3|d)\propto 0.4\cdot 0.2=0.08$ 。
- 正类得票 0.15；负类得票  $0.09+0.08=0.17 > 0.15 \rightarrow$  分类为负类(-)。

题型三：α-β 剪枝（第5章）☆☆☆

规则速记

- MAX 层取子节点最大值，MIN 层取最小值。α=MAX 已找到的最大下界，β=MIN 已找到的最小上界，初始  $\alpha=-\infty, \beta=+\infty$ 。
- α 剪枝：在 MIN 节点，若其当前值 ≤ 祖先 MAX 的 α，剪掉该 MIN 剩余分支。
- β 剪枝：在 MAX 节点，若其当前值 ≥ 祖先 MIN 的 β，剪掉该 MAX 剩余分支。
- 口诀：MIN 节点 ≤ α 剪；MAX 节点 ≥ β 剪。从左到右生成。

解题步骤

- 从左到右深度优先遍历，先到叶子拿值。
- 自底向上回传，MAX 取大、MIN 取小，同时更新 α/β。
- 一旦某节点满足剪枝条件，在该处标记"剪枝"并停止扩展其右侧兄弟。
- 在博弈树上明确标出在哪条边/哪个节点发生剪枝。

例题思路

对给定博弈树，按"左优先"逐叶取值，回传时比较 α/β。凡是"MIN 节点已得值 ≤ 上层 α"或"MAX 节点已得值 ≥ 上层 β"处画剪枝标记。答题时要写清：①各节点回传值；②每处剪枝的位置和原因(值 vs α/β)。

题型四：A\* 搜索 OPEN/CLOSED 表（第5章）☆☆☆

通用方法

- $f(n) = g(n) + h(n)$ 。OPEN 表存待扩展节点(按 f 排序)，CLOSED 表存已扩展节点。
- 每步：从 OPEN 取 f 最小的节点扩展 → 移入 CLOSED → 生成子节点算 f 放入 OPEN。

八数码例题模板

- $h(n)$  = 每个将牌到目标位置的曼哈顿距离之和（或错位将牌数）； $g(n)$ =深度  $d(n)$ 。
- 逐步列表：

| 步骤  | 当前扩展节点(f)  | OPEN 表(节点:f) | CLOSED 表 |
|-----|------------|--------------|----------|
| 1   | S0 (f=d+h) | {子节点们:f值}    | {}       |
| 2   | 选f最小者扩展    | 更新后 OPEN     | {S0}     |
| ... |            |              |          |

- 答题要求：①列前三步 OPEN/CLOSED 内容与扩展节点 f 值；②画前 6 步搜索树并标 f 值。

简单图例题

给节点 h 值和边 g 值，从 s 到 G：

- 初始  $OPEN=[s(f=h(s))]$ ，扩展 s，把邻居按  $f=g+h$  放入 OPEN，每次取 f 最小扩展，记录 OPEN 变化，直到扩展到 G。写出最优路径与总代价。

题型五：决策树 ID3 信息增益（第6章）☆☆☆

公式

- 信息熵：  $Ent(D) = -\sum_i p_i \cdot \log_2(p_i)$ ， $p_i$  为第 i 类样本占比。
- 某属性 a 的条件熵：  $Ent(D,a) = \sum_v (|D_v|/|D|) \cdot Ent(D_v)$ ， $D_v$  为属性取值 v 的子集。
- 信息增益  $Gain(D,a) = Ent(D) - Ent(D,a)$ 。选信息增益最大的属性作分裂节点。

例题模板（挑瓜/PlayTennis 类）

第一步：算总熵  $Ent(D)$ 。设正例 p 个、反例 n 个，共 p+n：

$Ent(D) = -[p/(p+n)]\log_2[p/(p+n)] - [n/(p+n)]\log_2[n/(p+n)]$ 。

（如 8 正 8 反：  $Ent = -0.5\log_2 0.5 - 0.5\log_2 0.5 = 1$ ；9 正 5 反：  $Ent = -(9/14)\log_2(9/14) - (5/14)\log_2(5/14) \approx 0.940$ ）

第二步：对每个候选属性，按取值分组，算各组熵，加权求条件熵  $\text{Ent}(D,a)$ 。

第三步： $\text{Gain} = \text{Ent}(D) - \text{Ent}(D,a)$ ，比较所有属性，选增益最大者。

常用  $\log_2$  值： $\log_2 1=0$ ,  $\log_2 2=1$ ,  $\log_2 3\approx 1.585$ ,  $\log_2 4=2$ ,  $\log_2 5\approx 2.322$ ,  $\log_2(1/2)=-1$ ,  $\log_2(2/3)\approx -0.585$ ,  $\log_2(1/3)\approx -1.585$ 。

若题目要求“预测某样本类标记”：从根节点按属性取值一路走到叶节点，叶节点多数类即预测结果。也可用朴素贝叶斯： $P(\text{类}|\text{X}) \propto P(\text{类}) \cdot \prod P(\text{属性}|\text{类})$ ，比较大小取大者。

## 题型六：神经网络计算（第7章）☆☆☆【重点·必考复杂版】

### 6.1 卷积输出尺寸

公式：输出 = (输入 - 卷积核 + 2·填充) / 步幅 + 1。

- 例：7×7 输入，3×3 核，步幅 1，无填充 →  $(7-3)/1+1 = 5 \times 5$ 。
- 带填充 padding=P： $(W-F+2P)/S+1$ 。多通道时输出通道数=卷积核个数。

### 6.2 加法/乘法节点梯度反传（★复杂版重点★）

反向传播链式法则，记住三个基本门的局部梯度：

- 加法门  $z=x+y$ ：梯度直接传递， $\partial z/\partial x=1$ ,  $\partial z/\partial y=1$ 。上游梯度  $g$  原样分给两条输入 → 都是  $g$ 。
  - 例：C=A+B, A=3,B=4,C=7, C 处梯度 2 → A、B 梯度都是 **2,2**。
- 乘法门  $z=x \cdot y$ ：梯度交叉相乘， $\partial z/\partial x=y$ ,  $\partial z/\partial y=x$ 。上游梯度  $g \rightarrow x$  得  $g \cdot y$ ,  $y$  得  $g \cdot x$ 。
- max 门：梯度只走向较大的那个输入，另一个为 0。
- 复制/分支：多个下游梯度相加回传。

Max 门完整例题（ReLU / MaxPooling 常见）：

取最大值操作，A 处输入 3，B 处输入 7，C 处输出 7 ( $C=\max(A,B)$ )。若 C 处梯度为 2，求 A、B 处梯度。

Max 门局部梯度： $C = \max(A,B)$   
因  $B=7 > A=3$ ，输出完全由 B 决定，与 A 无关：  
 $\partial C/\partial A = 0$  (A 不是最大值，对输出无贡献)  
 $\partial C/\partial B = 1$  (B 就是最大值本身)  
链式法则（上游梯度 2 往回传）：  
 $\partial L/\partial A = 2 \times 0 = 0$   
 $\partial L/\partial B = 2 \times 1 = 2$

答案：A、B 梯度分别为 **0, 2**。

口诀：max 门是“梯度路由器”——上游梯度原样传给较大的输入，另一个输入梯度为 0。ReLU 是  $\max(0,z)$  的特例： $z>0$  传 1， $z\leq 0$  传 0。

### 6.3 向量计算图梯度（往年卷计算题4）

函数如  $y = [x_1+x_2, x_2, x_3, x_4]$ （某分量是多个  $x$  的组合）。已知  $\partial L/\partial y = [4, -1, 5, 9]$ ，求  $\partial L/\partial x$ ：

$\partial L/\partial x_1 = \partial L/\partial y_1 \cdot (\partial y_1/\partial x_1) = 4 \cdot 1 = 4$   
 $\partial L/\partial x_2 = \partial L/\partial y_1 \cdot 1 + \partial L/\partial y_2 \cdot 1 = 4 + (-1) = 3$  ←  $x_2$  影响  $y_1$  和  $y_2$ ，梯度相加  
 $\partial L/\partial x_3 = \partial L/\partial y_3 = 5$   
 $\partial L/\partial x_4 = \partial L/\partial y_4 = 9$

结果  $\partial L/\partial x = [4, 3, 5, 9]$ 。

关键：一个输入影响多个输出时，各路径梯度相加（这正是“复杂版”的考点）。

### 6.4 AND 神经元求 $w_1, w_2, b$ （★必考·复杂版可能换成 OR/NAND★）

神经元： $\text{net} = w_1x_1 + w_2x_2 + b$ ，输出  $y = f(\text{net})$ ， $f$  为阶跃函数（ $\text{net} \geq 0$  输出 1，否则 0）或题给激活函数。

AND 真值表约束（输出：0,0→0; 0,1→0; 1,0→0; 1,1→1）：

(0,0):  $b < 0$  (阈值判据  $\text{net} < 0$ )  
(0,1):  $w_2 + b < 0$   
(1,0):  $w_1 + b < 0$   
(1,1):  $w_1 + w_2 + b \geq 0$

一组可行解： $w_1 = w_2 = 1, b = -1.5$ （验证： $0+0-1.5<0\checkmark, 1-1.5<0\checkmark, 2-1.5\geq 0\checkmark$ ）。

往年卷给的另一组解  $w_1=w_2=0.7, b=0$  是配合特定激活函数（如  $\text{net}>0.5$  才输出 1）的写法。只要满足真值表的不等式组即可，解不唯一，答题写出不等式组 + 一组解 + 验证。

举一反三：

- **OR 函数**：w<sub>1</sub>=w<sub>2</sub>=1, b=-0.5。
- **NAND**：w<sub>1</sub>=w<sub>2</sub>=-1, b=1.5。
- **复杂版**：可能给"源×权重矩阵×偏置×激活函数"的多神经元前向计算，或要你对多层网络做一次完整前向+反向。方法不变：逐层 net=Wx+b → 激活 → 输出；反向用链式法则从损失往回求各 W 的梯度。

6.5 前馈网络损失 + 反向传播（jk2 第29、30条，可能大题）

完整流程模板：

1. **前向**：隐层 h = f(W<sub>1</sub>x + b<sub>1</sub>)；输出 ŷ = g(W<sub>2</sub>h + b<sub>2</sub>)。
  2. **损失**：如均方误差 L = ½(ŷ-y)² 或交叉熵。
  3. **反向**：
    - 输出层误差 δ<sub>out</sub> = (ŷ-y)·g'(net<sub>out</sub>)
    - ∂L/∂W<sub>2</sub> = δ<sub>out</sub> · h<sup>T</sup>
    - 隐层误差 δ<sub>h</sub> = (W<sub>2</sub><sup>T</sup>δ<sub>out</sub>) ⊙ f'(net<sub>h</sub>)
    - ∂L/∂W<sub>1</sub> = δ<sub>h</sub> · x<sup>T</sup>
  4. **更新**：W ← W - α·∂L/∂W。
- 常用导数：Sigmoid σ'(x)=σ(x)(1-σ(x))；ReLU'(x)= 1(x>0) 否则 0；tanh'(x)=1-tanh²(x)。

6.6 两类损失函数 + Softmax 交叉熵联合梯度（jk2 第29条）

| 损失函数      | 公式                                            | 适用场景 |
|-----------|-----------------------------------------------|------|
| MSE（均方误差） | L = (1/N)Σ(y <sub>i</sub> - ŷ <sub>i</sub> )² | 回归任务 |
| 交叉熵       | L = -Σ y <sub>i</sub> ·log(ŷ <sub>i</sub> )   | 分类任务 |

交叉熵细节：

- y<sub>i</sub> 是真实标签的 **one-hot 编码**，ŷ<sub>i</sub> 是预测概率；衡量两个概率分布的差异。
- 分类计算流程：①前向得最后一层输出 z；②Softmax：ŷ<sub>i</sub> = e<sup>^(z<sub>i</sub>)/Σe<sup>^(z<sub>j</sub>)</sup>（归一化概率）；③交叉熵 L = -Σ y<sub>i</sub>·log(ŷ<sub>i</sub>)；④L 即损失值，反向从此出发。</sup>

★关键简化式★：交叉熵 + Softmax 联合求导，输出层梯度极简洁：

dz = ŷ - y

（预测概率 - 真实 one-hot，直接相减）

这是为什么分类网络输出层用 Softmax+交叉熵——梯度形式和回归的 (ŷ-y) 一样干净，反向传播的起点就是"预测减真实"。

6.7 反向传播的三层网络矩阵梯度流（jk2 第30条）

核心：用链式求导法则，从输出层向输入层逐层计算损失对各参数的梯度。（历史：1974 Werbos 提出 → 1986 Rumelhart & Hinton 完善推广。）

三层网络的通用梯度公式（L 表示层号）：

输出层：dz^(L) = a^(L) - y

（预测 - 真实，起点）

隐藏层：dz^(l) = (W^(l+1))^T · dz^(l+1) ⊙ f'(z^(l))

（误差反向传播，⊙ 为逐元素乘）

权重梯度：∂L/∂W^(l) = dz^(l) · (a^(l-1))^T

偏置梯度：∂L/∂b^(l) = dz^(l)

更新规则：W ← W - η·∂L/∂W,    b ← b - η·∂L/∂b

对照 6.5 的标量版：δ<sub>out</sub>=(ŷ-y)·g'、∂L/∂W<sub>2</sub>=δ<sub>out</sub>·h<sup>T</sup>、δ<sub>h</sub>=(W<sub>2</sub><sup>T</sup>δ<sub>out</sub>)⊙f'(net<sub>h</sub>) 就是这套公式的两层实例。

三种梯度下降变体（可能考选择/简答）：

| 变体 | 每步用多少数据 | 特点 |

|---|---|---|

| 批量梯度下降（BGD） | 全数据集 | 最准确但最慢 |

| 随机梯度下降（SGD） | 1 个样本 | 快但不稳定 |

| 小批量梯度下降（Mini-batch） | 若干样本（batch） | 折中，实际最常用 |

意义：反向传播解决了多层网络参数优化难题，是深度学习的基石。

题 · 两层神经网络完整前向 + 反向传播

网络结构

一个两层网络(1 个隐藏层 + 1 个输出层),用来做回归。

输入 x → [隐藏层 2个神经元, 激活ReLU] → [输出层 1个神经元, 线性] → 预测 ŷ

↓

$$\text{损失 } L = \frac{1}{2}(\hat{y} - y)^2$$

## 给定参数(全部已知)

输入与真值:

$x = [1, 2]$  (两维输入)  
 $y = 1$  (真实标签)

隐藏层(2 个神经元,各接收 2 维输入):

$W1 = \begin{bmatrix} 0.1 & 0.3 \\ 0.2 & 0.4 \end{bmatrix}$ ,  $b1 = \begin{bmatrix} 0.1 \\ 0.2 \end{bmatrix}$

即:神经元1 权重  $[0.1, 0.3]$ , 偏置  $0.1$   
神经元2 权重  $[0.2, 0.4]$ , 偏置  $0.2$   
激活:ReLU,  $f(z) = \max(0, z)$

输出层(1 个神经元,接收 2 维隐藏输出):

$W2 = [0.5, 0.6]$   $b2 = 0.1$   
激活:线性(不加激活)

学习率  $\alpha = 0.1$

## 要求

- 做一次完整前向传播,求预测值  $\hat{y}$  和损失  $L$
- 做一次完整反向传播,求所有参数的梯度
- 用梯度下降更新一次  $W2$

## 解答

### 第一步:前向传播(逐层 $\text{net} = Wx+b \rightarrow$ 激活)

隐藏层净输入  $\text{net1}$ :

神经元1:  $z1 = 0.1 \times 1 + 0.3 \times 2 + 0.1 = 0.1 + 0.6 + 0.1 = 0.8$   
神经元2:  $z2 = 0.2 \times 1 + 0.4 \times 2 + 0.2 = 0.2 + 0.8 + 0.2 = 1.2$

隐藏层激活(ReLU):

$h1 = \max(0, 0.8) = 0.8$   
 $h2 = \max(0, 1.2) = 1.2$   
 $h = [0.8, 1.2]$

输出层(线性):

$\hat{y} = 0.5 \times 0.8 + 0.6 \times 1.2 + 0.1 = 0.4 + 0.72 + 0.1 = 1.22$

损失:

$$L = \frac{1}{2}(\hat{y} - y)^2 = \frac{1}{2}(1.22 - 1)^2 = \frac{1}{2}(0.22)^2 = \frac{1}{2} \times 0.0484 = 0.0242$$

### 第二步:反向传播(链式法则,从损失往回)

#### (a) 损失对输出的梯度

$$\partial L / \partial \hat{y} = (\hat{y} - y) = 1.22 - 1 = 0.22$$

#### (b) 输出层参数 $W2$ 、 $b2$ 的梯度

因为  $\hat{y} = W2 \cdot h + b2$ , 所以  $\partial \hat{y} / \partial W2 = h$ :

```
∂L/∂W2_1 = ∂L/∂ŷ × h1 = 0.22 × 0.8 = 0.176
∂L/∂W2_2 = ∂L/∂ŷ × h2 = 0.22 × 1.2 = 0.264
∂L/∂b2    = ∂L/∂ŷ × 1   = 0.22

∇W2 = [0.176, 0.264],   ∇b2 = 0.22
```

(c) 梯度传到隐藏层输出 h

```
∂L/∂h1 = ∂L/∂ŷ × W2_1 = 0.22 × 0.5 = 0.11
∂L/∂h2 = ∂L/∂ŷ × W2_2 = 0.22 × 0.6 = 0.132
```

(d) 穿过 ReLU(你笔记里的门控:z>0 传1,z≤0 传0)

```
z1=0.8>0 → i'=1 → ∂L/∂z1 = 0.11 × 1 = 0.11
z2=1.2>0 → i'=1 → ∂L/∂z2 = 0.132 × 1 = 0.132
```

(若某个 z≤0, 这里就乘 0, 梯度被截断)

(e) 隐藏层参数 W1、b1 的梯度

因为  $z = W1 \cdot x + b1$ ,  $\partial z / \partial W1 = x = [1, 2]$ :

```
神经元1:
∂L/∂W1_11 = 0.11 × x1 = 0.11 × 1 = 0.11
∂L/∂W1_12 = 0.11 × x2 = 0.11 × 2 = 0.22
∂L/∂b1_1  = 0.11


神经元2:
∂L/∂W1_21 = 0.132 × x1 = 0.132 × 1 = 0.132
∂L/∂W1_22 = 0.132 × x2 = 0.132 × 2 = 0.264
∂L/∂b1_2  = 0.132
```

第三步:更新一次 W2( $\theta = \theta - \alpha \nabla$ )

```
W2_1 = 0.5 - 0.1×0.176 = 0.5 - 0.0176 = 0.4824
W2_2 = 0.6 - 0.1×0.264 = 0.6 - 0.0264 = 0.5736
b2    = 0.1 - 0.1×0.22  = 0.1 - 0.022  = 0.078

更新后 W2 = [0.4824, 0.5736],   b2 = 0.078
```

一图看懂数据流向



对应你笔记的三步梯度下降

- ① 初始化参数 → W1, W2, b1, b2 已给
- ② 算梯度 → 前向得损失, 反向用链式法则(ReLU 门控 z>0传1、z≤0传0)
- ③  $\theta = \theta - \alpha \nabla J(\theta)$  → 更新 W2 = [0.4824, 0.5736]

题型七: ROC 曲线与 AUC 计算 (模型评估) ★★

核心概念

- **TPR** (真正率, 纵轴) = TP/(TP+FN), 也叫召回率/查全率。
- **FPR** (假正率, 横轴) = FP/(FP+TN)。

- ROC 曲线：把分类阈值从高到低滑动，每个阈值算一对 (FPR, TPR) 描点连线得到。
- **AUC** = ROC 曲线下的面积，范围 [0,1]，越大越好（0.5=随机猜测，1=完美）。

计算步骤

1. 按预测得分**从高到低**排序样本，逐个把阈值下移，样本依次判为正例。
2. 每移动一次算当前 (FPR, TPR)，得到一串坐标点（从 (0,0) 到 (1,1)）。
3. **梯形公式**沿横轴累加面积：

$$AUC = \sum \frac{1}{2}(TPR_i + TPR_{i-1}) \times (FPR_i - FPR_{i-1})$$

例题（梯形法逐段算 AUC）

排序后得到 6 个点的 (FPR, TPR)，逐段算面积（只有 **FPR** 变化的段才有面积，**FPR** 不变的段宽=0、面积=0）：

点1~2：FPR不变(0~0)，宽=0，面积=0  
点2~3：FPR不变(0~0)，宽=0，面积=0  
点3~4：FPR 0~0.5，宽=0.5；TPR 0.67~0.67  
    面积 =  $\frac{1}{2}(0.67+0.67) \times 0.5 = 0.67 \times 0.5 = 0.335$   
点4~5：FPR不变(0.5~0.5)，宽=0，面积=0  
点5~6：FPR 0.5~1.0，宽=0.5；TPR 1.0~1.0  
    面积 =  $\frac{1}{2}(1.0+1.0) \times 0.5 = 1.0 \times 0.5 = 0.5$   
AUC = 0.335 + 0.5 = 0.835 ≈ 5/6

答题要点：①先把点按 FPR 递增排好；②逐段用梯形公式，横向宽度是 ΔFPR、上下底是相邻两点的 TPR；③FPR 不变的段直接跳过（面积 0）。

附：计算题应试要点

- 写清过程：所有计算题都要求“写出计算过程”，只写答案不给分。
- 贝叶斯/熵：小数逐项写、别跳步，log<sub>2</sub> 值提前记熟。
- 归结：每一步标明用哪两个子句、合一代换是什么。
- 神经网络：先写公式，再代数，最后验证真值表/给结果。
- 搜索：OPEN/CLOSED 表逐步列清，f=g+h 每个都标。
- ROC/AUC：先把点按 FPR 递增排序，梯形公式逐段累加，FPR 不变段跳过。