

第二讲 并行计算体系结构 (1)


何克晶

kejinghe@gmail.com

华南理工大学

计算机科学与工程学院

HPC硬件平台架构



服务器
(计算/管理)

三种计算节点:

- 传统MPI节点 (瘦节点): 高性能刀片或者机架服务器;
- 胖服务器节点: SMP架构高性能服务器, 具备多CPU和大内存容量;
- 加速节点: 服务器中安装GPU/NPU/TPU卡, 进行运算加速。

交换机

三平面组网:

- 计算网络: 用于计算过程中的消息传递;
 - 管理网络: 用于集群系统管理 (带内/带外);
 - 存储网络: 用于存储或者数据传输。
- 术语解释:
- MPI: Message Passing Interface消息传递函数库接口。

存储系统

并行计算机网络


概述

静态互联网络

动态互联网络

标准实现


A Generic Parallel Architecture



并行计算机网络性能指标


- 节点度 (Node Degree) : 射入或射出一个节点的边数。在单向网络中, 入射和出射边之和称为节点度。
- 网络直径 (Network Diameter) : 网络中任何两个节点之间的最长距离, 即最大路径数。
- 对剖宽度 (Bisection Width) : 对分网络各半所必须移去的最少边数
- 如果从任一节点观看网络都一样, 则称网络为对称的 (Symmetry)
- 对剖带宽 (Bisection Bandwidth) :每秒钟内, 在最小的对剖平面上通过所有连线的最大信息位 (或字节) 数
- 网络规模: 网络包含的结点总数, 或者包含的CPU 总数。

Latency



$$\text{Total Latency} = \text{Sender Overhead} + \text{Time of Flight} + \text{Message Size} \div \text{BW} + \text{Receiver Overhead}$$

Bandwidth



- **Overhead:** latency of interface vs. **Latency:** network

How to use them?

- 固定网络规模

- 对剖带宽 越高
- 对剖宽度 越大
- 或者网络直径 越小
- 则互联网络质量可以说越高

并行计算机网络

概述

静态互联网络

动态互联网络

标准实现


静态连接

- 处理单元间有着固定连接的一类网络，在程序执行期间，这种点到点的链接保持不变
- 典型的静态网络：
 - 一维线性阵列、二维网孔、树连接、超立方网络、立方环、洗牌交换网、蝶形网络等

一维线性阵列




Linear Array



Ring

- 并行机中最简单最基本的互连方式
- 每个节点只与其左、右近邻相连，也叫二近邻连接
- N 个节点用 $N-1$ 条边串接之，内节点度为2，直径为 $N-1$ ，对剖宽度为1
- 当首、尾节点相连时可构成循环移位器，在拓扑结构上等同于环，环可以是单向的或双向的
 - 节点度恒为2
 - 直径或为 $\lfloor N/2 \rfloor$ (双向环) 或为 $N-1$ (单向环)
 - 对剖宽度为2
- 例子：FDDI, SCI

二维网孔




2D-Mesh



- 每个节点只与其上、下、左右的近邻相连(边界节点除外)
 - 网络规模: N
 - 节点度: 4
 - 网络直径: $2(N^{1/2} - 1)$
 - 对剖宽度: $N^{1/2}$
- 例子: Intel paragon

二维网孔2


- 在垂直方向上带环绕，水平方向呈蛇状，就变成Illiac网孔了
- 节点度恒为4，网络直径为 $N^{1/2}-1$ ，而对剖宽度为 $2N^{1/2}$
- 垂直和水平方向均带环绕，则变成了2D环绕(2D Torus)
- 节点度恒为4，网络直径为 $2\lfloor N^{1/2}/2 \rfloor$ ，对剖宽度为 $2N^{1/2}$



二叉树




- 除了根、叶节点，每个内节点只与其父节点和两个子节点相连
 - 节点度为3（三近邻连接），对剖宽度为1
 - 树的直径为 $2 * k - 2 = 2(\lceil \log_2 N \rceil - 1)$ （ k 为层数， N 为树的总节点数）
- 如果尽量增大节点度为 $N-1$ ，则直径缩小为2，此时就变成了星形网
 - 对剖宽度为 $\lfloor N/2 \rfloor$





标准二叉树拓扑结构包含 $P=2^N$ 个叶结点和 2^N-1 个内结点。

胖树




- 传统二叉树的主要问题是根节点容易成为通信瓶颈。胖树节点间的通路自叶向根逐渐变宽
- 对剖带宽随着N的增大而增大
- 例子：Infiniband

超立方



超立方




- 节点用n个二进制编码
- 两节点编号中数码不同的位数即为两节点的距离。
- 两节点编号只有一位不同，肯定是相邻节点。

超立方

- 是一个具有很好性质的拓扑结构，其网络直径仅为 $\log P$ ，折半带宽为 $2^{(d-1)}$ 。
- 结点的度为 d ，随并行机规模的增加而增加，这给网络实现带来了一定的困难。
- 通常地，超立方体一般不超过5 维。


3-D Torus




4-ary 3-Cube
(4元3立方体)

A k -ary d -cube (There are k nodes along all d axes with end around connections.), is an interconnection network with k^d nodes and is a generalization of the mesh and hypercube interconnects.


k-立方环




(a) 3-立方



(b) 4-立方



(c) 顶点代之以环



(d) 3-立方环

$$N = k \cdot 2^k$$

节点度=3

静态互连网络特性比较

网络名称	网络规模	节点度	网络直径	对剖宽度	对称	链路数
线性阵列	N	2	$N-1$	1	非	$N-1$
环形	N	2	$\lfloor N/2 \rfloor$	2	是	N
2-D网孔	$N=n^2$	4	$2(n-1)$	n	非	$2(N-n)$
Illiac网孔	$N=n^2$	4	$n-1$	$2n$	非	$2N$
2-D环绕	$N=n^2$	4	$2\lfloor n/2 \rfloor$	$2n$	是	$2N$
二叉树	N	3	$2(\lceil \log_2 N \rceil - 1)$	1	非	$N-1$
星形	N	$N-1$	2	$\lfloor N/2 \rfloor$	非	$N-1$
超立方	$N=2^n$	$\log_2 N=n$	n	$N/2$	是	$nN/2$
立方环	$N=k \cdot 2^k$	3	$2k-1+\lfloor k/2 \rfloor$	$N/(2k)$	是	$3N/2$

并行计算机网络

概述

静态互联网络


动态互联网络

标准实现

动态互联网络

- 结点之间无固定的物理连接，而是在连接路径的交叉点处用电子开关、路由器或仲裁器等提供动态连接
- 主要包含单一总线、多层总线、交叉开关、多级互联网络等类型。
- 多处理机总线系统的主要问题：
 - 包括总线仲裁、中断处理、协议转换、快速同步、高速缓存一致性协议、分事务、总线桥和层次总线扩展等

总线 (Bus)




总线 (Bus)

- 连接处理器、存储模块和I/O 设备等的一组导线和插座，在主设备（处理器）和从设备（存储器）之间传递数据。
- 三个特征：
 - 公用总线以分时工作为基础，各处理器模块分时共享总线带宽，即在同一个时钟周期，至多只有一个设备能占有总线；
 - 总线带宽=总线主频*总线宽度，例如假设主板的总线频率为150MHz，总线宽度为64位，则该总线的带宽为1.2GB/s；
 - 采用公平的监听协议与仲裁算法，以确定在某个时刻选择哪个设备占有总线。

总线 (Bus)

- Bus: PCI、VME、Multics、Sbus、MicroChannel, IEEE Futurebus




- Degree: 1
- Diameter: 1
- Size: N
- Networking: too bad
- Scalability: good
- Fault-tolerance: too bad
- Easy to implement, low prices

交叉开关 (Crossbar)

- 所有结点通过交叉开关阵列相互连接，每个交叉开关均为其中两个结点之间提供一条专用连接通路，同时，任意两个结点之间也能找到一个交叉开关，在它们之间建立专用连接通路。
- 三个特征：
 - 结点之间的连接：交叉开关一般构成 $N \times N$ 阵列，但在每一行和每一列同时只能有一个交叉点开关处于“开”状态，从而它同时只能接通 N 对结点。
 - 一般地，结点和存储器模块作为连接的对象，分别分布在拓扑结构的两侧。
 - 结构为 $N \times N$ 的交叉开关只能提供 $2 \times N$ 个端口，这限制了它在大规模并行机中的应用。交叉开关一般仅适合数个处理器的情形，或者，在结点内部为处理器和存储器之间提供快速高效的通道

交叉开关 (Crossbar)


- 单级交换网络，可为每个端口提供更高的带宽。
 - 电话交换机一样，交叉点开关可由程序控制动态设置其处于“开”或“关”状态，而能提供所有（源、目的）对之间的动态连接。
- 交叉开关一般有两种使用方式：
 - 一种是用于对称的多处理机或多计算机机群中的处理器间的通信；
 - 另一种是用于SMP服务器或向量超级计算机中处理器和存储器之间的存取。



Input 2 is connected to output 2,
input 3 is connected to output 4,
input 4 is connected to output 3.

Note: Connections between free
inputs and outputs are always possible.

交叉开关 (Crossbar)



A Small Crossbar Switch

- **Degree: 1**
- **Diameter: 1**
- **Size: $O(N^2)$**
- **Networking: excellent**
- **Scalability: general**
- **Fault-tolerance: general**
- **powerful, expensive**
- **Example: SGI Option Blue Mountain**

交叉开关 (Crossbar)

- 交换开关模块：


- 一个交换开关模块有 n 个输入和 n 个输出，每个输入可连接到任意输出端口，但只允许一对一或一对多的映射，不允许多对一的映射，因为这将发生输出冲突。

- 级间互连 (Interstage Connection)：


- 均匀洗牌、蝶网、多路均匀洗牌、交叉开关、立方连接。
- n 输入的 Ω 网络需要 $\log_2 n$ 级 2×2 开关，在Illinois大学的Cedar[2]多处理机系统中采用了 Ω 网络。
- Cray Y/MP多级网络，该网络用来支持8个向量处理器和256个存储器模块之间的数据传输。网络能够避免8个处理器同时进行存储器存取时的冲突。

多级互连网络 (MIN)

- 单级交叉开关级联起来形成多级互连网络MIN (Multistage Interconnection Network)




(a) 4种可能的开关连接



(b) 一种8输入的Omega网络

Ω Network




ISC: Perfect-Shuffle


Examples: IBM SP2, IBM option white, IBM Blue Pacific

ISC: Inter-Stage Connection


- Butterfly (蝶式)



- Shuffle (均匀洗牌)




多级互连网络 (MIN)



ISC: Inter-stage Connection (级间链接)

- **Degree: 1**
- **Diameter: $\log N$**
- **Size: $N \log N$**
- **Networking: good**
- **Scalability: general**
- **Fault-tolerance: general**
- **Easy to implement, moderate price**

动态网络（举例）



用8个4×4的交叉开关构成二级16×16的交叉开关网络



动态互连网络比较

动态互连网络的复杂度和带宽性能一览表

Networks	Delay	Cost	Blocking	Example
Bus	$O(N)$	$O(1)$	Yes	SunFire Gigaplane Bus: 2.67GB/s
MINs	$O(\log N)$	$O(N \log N)$	Yes	IBM SP2: 10.24GB/s
Crossbar	$O(1)$	$O(N^2)$	No	Digital Giga Switch: 3.4GB/s

并行计算机网络

概述

静态互联网络


动态互联网络

标准实现

Standard Interconnection Network

- Ethernet
- Infiniband
- RoCE


以太网



50 Years of Ethernet History (1973-Current)


以太网

History of Ethernet LAN Cables' Categories



All Rights Reserved, Samm Teknoloji / telecom.samm.com / telecom@samm.com


RoCE



RDMA (Remote Direct Memory Access) 技术是一种直接在内存和内存之间进行数据互传的技术，在数据传输的过程中完全实现了Kernel Bypass，CPU不需要参与操作，这也是RDMA在降低CPU消耗的同时，还能带来低时延的原因。

RoCE网络类型

目前，大致有三类RDMA网络，分别是Infiniband、RoCE、iWARP。其中，Infiniband是一种专为RDMA设计的网络，从硬件级别保证可靠传输，而RoCE和iWARP都是基于以太网的RDMA技术，支持相应的verbs接口。




RDMA从Infiniband承载协议演进到以太网TCP/UDP承载协议。基于TCP的RDMA，本质上是将“无损”寄托在TCP的可靠性上，而基于RoCEv2的无损网络则是将“无损”放在了流控机制。


Infiniband

- A New Generation Computing, Communication and I/O Architecture
 - defines a System Area Network for connecting processing and I/O nodes
 - Communications and management infrastructure for IPC (Inter-Process Communication) and I/O
 - Switched, channel-based interconnection fabric
- Goal: To design a scalable and high performance communication and I/O by taking an integrated view of computing, networking and storage technologies
- IBTA (Infiniband Trade Association) established in 1999
 - Led by: Cisco, IBM, Intel, Mellanox, QLogic, Sun and Voltaire (Members: Compac, Dell, HP, Microsoft etc.)
 - www.infinibandta.org

RDMA网络的关键技术




RoCE v2




CNP (Congestion Notification Packets)

- PFC, ECN的一些信息, 如ECN的阈值设置、被标记的ECN包的数量等
- 降速模式、停止发送
- Telemetry, RoCE 流量 KPI 分析
- When the buffer used by the queue exceeds the ECN threshold, the device adds the ECN field of 11 to packets to be forwarded.
- After the source server receives the CNP, it reduces the packet sending rate.
- When the queue exceeds the PFC threshold, the device sends a PFC notification packet to the source server. After receiving the PFC notification packet, the source server stops sending packets from the queue with a specified priority.
- When congestion of Queue-n is relieved and the buffer used by the queue is lower than the PFC threshold, the device sends a PFC pause packet to the source server. After receiving the PFC pause packet, the source server continues to send packets from the queue with a specified priority.

RoCE v2




HPC 网络：AI Fabric的目标




构建DCN新一代极速无损以太网，高吞吐，低时延，满足AI业务诉求。

HPC 网络：AI Fabric典型组网方案

大规模二级组网



小型一级组网



25GE/100GE线速互联

- CE16800单板支持36*100GE互联。
- CE8850-64CQ-EI支持64*100GE互联。
- CE8861EI灵活插卡，支持32*100GE接入，支持4*25GE拆分。
- CE6865EI支持48*25GE接入，8*100GE上行。
- 支持1:1无阻塞组网。
- TOR/EOR多种方式接入。

* CE16800做Leaf节点，可通过增加接入设备的端口密度，将业务通信尽量限制在一台设备下，通过流控可实现业务无损，并通过减少跳数降低网络时延。

超大规模服务器接入能力


- 高密度25GE/100GE端口接入。
- 25GE/100GE服务器规模部署[1K~5K台]。

满足云计算场景东西向流量


- 25GE/100GE高速端口大缓存应对突发流量。
- 独特**拥塞控制算法**，提升RoCEv2分布式应用性能。

Top500 (Interconnect Family)

Interconnect Family System Share







Interconnect Family Performance Share



Interconnect Family (2022.6)

Top500中的网络互连



谢谢